

Approachable by Design: Baby Schema and Emotional Responsiveness as a Low-Threshold Entry Point to Robotics

Alexander Scheidl

Abstract—[TODO: Abstract zuletzt schreiben, ca. 150–200 Woerter, keine Zitate, keine Formeln.]

Der Abstract muss diese drei Punkte abdecken – je ein bis zwei Sätze:

- **Motivation:** Robotik wird alltagsrelevant, der Erstkontakt ist aber von Skepsis geprägt; aus der Psychologie ist bekannt, dass Kindchenschema und emotionale Reagibilität Hemmschwellen senken.
- **Beitrag:** Umsetzung dieser Mechanismen auf einem Roboter mit stark reduzierten Ausdrucksmitteln (6-DoF-Kopf, zwei Antennen, kein Gesicht), aufgebaut auf Google MediaPipe und Vosk, sowie Vergleich mehrerer Skill-Konfigurationen.
- **Verifizierbarkeit:** Messung von Reaktionszeit und Wiederholbarkeit ueber vier Konfigurationen auf identischem, aufgezeichnetem Videostimulus.

I. INTRODUCTION

Ziel: ca. 0,6 Seiten. Fuenf Absaetze, je 3–5 Saezte. Roter Faden: Zugang zur Robotik → Hemmschwelle → Design als Hebel → was fehlt → was diese Arbeit tut.

[TODO: Absatz 1 – Thema.] Robots are moving from industrial cells into everyday environments, which makes the quality of a first encounter a design problem rather than a side effect.^[cite: HRI in everyday settings]

[TODO: Absatz 2 – Motivation.] Psychological research shows that appearance and emotional responsiveness systematically shape how approachable an artefact is perceived to be: baby-schema features activate reward and caretaking responses^[cite: Lorenz/Glocker], cute stimuli lower vigilance^{[cite: [1] Yim]}, and responsive behaviour drives anthropomorphic attribution^{[cite: [2] Rosenthal-von der Puetten]}.

[TODO: Absatz 3 – Problem.] These effects are usually demonstrated on images, videos or on complex humanoid platforms.^{[cite: [3] Rogel – naechstliegende Vorarbeit]} It is not obvious how far they carry over to a robot whose entire expressive channel consists of head pose and two antennas, and which must react in real time on commodity hardware.

[TODO: Absatz 4 – Beitrag (den Satz scharf formulieren!)] This paper presents a behaviour architecture for the Reachy Mini that deliberately targets the mechanisms above. It is built entirely from commodity perception components – Google MediaPipe for face and gesture input and Vosk for offline speech recognition – so that the contribution

lies in the behaviour layer rather than in perception. Four skill configurations of that architecture are evaluated with respect to reaction time and repeatability.

[TODO: Absatz 5 – Aufbau.] Section II reviews the relevant background, Section III describes platform, implementation and evaluation design, Section IV reports the measurements, and Section V concludes.

II. STATE OF THE ART

Ziel: ca. 0,6 Seiten. Hier liegt die gesamte psychologische Untermauerung. Wichtig: Der Abschnitt endet mit dem "So what" – was folgt daraus fuer die eigene Umsetzung. Ohne diesen Absatz haengt das Kapitel in der Luft.

A. Baby Schema and Perceived Approachability

[TODO: Kindchenschema: runde Formen, grosse Augen, kleine Nase; Aktivierung des Belohnungssystems; Fuersorgemotivation. Senkung der Wachsamkeit und erhoehrte Annaeherungsbereitschaft durch niedliche Reize.]^{[cite: Lorenz, Glocker, [1] Yim]}

B. Uncanny Valley and Stylised Design

[TODO: Warum comicartige, nicht-stereotypische Gestaltung das Uncanny Valley umgeht; Bewegungsqualitaet als zweiter Faktor neben Aussehen (Prediction Error bei Form-Bewegungs-Mismatch); stilisierte Koepfe als Gegenentwurf.]^{[cite: Mori, [4] Saygin, [5] Luetkebohle]}

C. Anthropomorphism and Emotional Attribution

[TODO: Zuschreibung von Absichten an bewegte Objekte; fMRI-Befunde zu Empathie gegenueber Robotern; Emotionszuschreibung als systematische Tendenz, nicht als Denkfehler; Waerme und Vertrauen bei positivem Gefuehlsausdruck.]^{[cite: [2] Rosenthal-von der Puetten, [6] Nitsch]}

D. Responsiveness as a Precondition for Bonding

[TODO: Bindungs-/Intimitaetsmodelle: Naehelikeit entsteht, wenn das Gegenueber zeitnahe und passend auf gezeigte Emotion eingeht und dabei Verstehen und Fuersorge vermittelt. Daraus folgt direkt die Messgrosse Reaktionszeit – eine Reaktion, die zu spaet kommt, wird nicht mehr als Antwort auf das eigene Verhalten gelesen.]^{[cite: [7] Reis & Shaver]}

E. Real-Time Perception Toolkits

[TODO: Zwei bis drei Sätze: Warum heute nicht mehr selbst trainiert wird.] Modern interactive systems typically rely on pre-trained, CPU-capable pipelines rather than on task-specific training. Google MediaPipe [4] provides such pipelines for face mesh, hand and gesture estimation, and Vosk [1] offers offline speech recognition for a range of languages. Both run locally, which keeps latency low and avoids any network dependency – a direct prerequisite for the contingency requirement discussed in Section II-D.

F. Expressive Robots with Reduced Degrees of Freedom

[TODO: Spannweite von anthropomorphen Köpfen mit vielen Gesichtsaktoren bis zu Systemen, die Affekt nur ueber Kopfbewegung und Antennen vermitteln. Fuer den Reachy Mini selbst: Beobachter bewerten positiven Gefuehlsausdruck als deutlich waermer, freundlicher und vertrauenswuerdiger – damit ist der reduzierte Kanal grundsatzlich ausreichend. Ggf. Keepon und Cozmo ergaenzen.]^{[cite: [3] Rogel, [5] Luetkebohle, minimal social robots]}

So what (Pflichtabsatz):**[TODO: Ein Absatz: Die genannten Systeme sind entweder proprietär, nicht rekonfigurierbar oder nicht auf Latenz hin dokumentiert. Daraus ergibt sich die Luecke – eine offene, messbar konfigurierbare Umsetzung auf reduzierter Hardware.]**

III. MATERIALS AND METHODS

Ziel: ca. 1,0 Seite. Hier steht, WAS gebaut wurde und WARUM – keine Ergebnisse. Jede Entwurfsentscheidung bekommt einen Begruendungssatz mit Rueckverweis auf Abschnitt II.

A. Design Rationale

Every design decision described in this section is derived from one of the mechanisms reviewed in Section II rather than from engineering convenience. Tab. 1 makes this mapping explicit and also states where the resulting property is verified in Section IV. **[TODO: Diese Tabelle ist das Herzstueck des Papers – sie verbindet Psychologie, Umsetzung und Messung. Zeilen pruefen und Querverweise anpassen, sobald die Abschnitte final nummeriert sind.]**

B. Platform

[TODO: Reachy Mini: 6-DoF-Kopf (Stewart-Plattform), Body-Yaw, zwei Antennen, keine Gliedmassen, kein beweglicher Gesichtsausdruck. Morphologie als gegebene Kindchenschema-Grundlage. Daemon/SDK, Ausfuehrung in Simulation bzw. auf Hardware.]^[cite: Reachy Mini]

C. Perception

All perception is performed on-device. Facial input is provided by the *FaceLandmarker* task of Google MediaPipe [4], which returns 478 facial landmarks together with 52 blend-shape coefficients per frame; the coefficients are aggregated into four affective categories by threshold. Hand input uses

Mechanism	Design decision	Verified in
Baby schema, caretaking (II-A)	Stylised morphology; vulnerability shown when personal space is entered (fear at close range)	Sec. IV-A
Lowered vigilance (II-A)	Expression through antennas and head only; no humanoid face to imitate	Sec. IV-B
Uncanny valley (II-B)	Minimum-jerk interpolation, smoothed gaze target, delayed body follow	Sec. IV-C
Anthropomorphic attribution (II-C)	Randomised pose variants instead of deterministic replay	Sec. IV-D
Contingency (II-D)	Decoupled mover thread, non-blocking target updates	Sec. IV-C
Validation and warmth (II-D)	Mirroring of joy; complementary response to anger and surprise	Sec. IV-A

Tab. 1: Each design decision is traced back to a psychological mechanism from Section II and forward to the measurement that verifies it.

the MediaPipe *GestureRecognizer* task for static poses, complemented by a custom waving detector. Speech is transcribed offline by Vosk [1] with the small German model.

[TODO: Kernidee erklären und als eigene Abbildung zeichnen: Ein Rechteck aus vier Landmarks (äußere Augenwinkel, Mundwinkel) liefert gleichzeitig das Blickziel (Mittelpunkt) und ein Distanzmaß (Fläche). Das ersetzt eine separate Face-Detection-Stufe und spart eine Inferenz pro Frame.]

D. Expression Library

[TODO: Emotion = Kopfpose + Antennenwinkel + Dauer. Mehrere Pose-Varianten je Emotion, zufällige Auswahl zur Vermeidung mechanischer Wiederholung – Begründung aus Abschnitt II-C.] Tab. 3 lists the implemented set.

E. Behaviour Logic

[TODO: Emotionszuordnung: Spiegelung bei Freude, komplementäre Reaktion bei Wut (Angst) und Ueberraschung (Neugier). Distanzregulation: nah → Angst, mittel → vorsichtig, weit → Spiegelung der erkannten Emotion. Gesten: Winken wird erwidert, während der Kopf weiter trackt. Rueckfall auf neutral nach Timeout.]

F. Motion Quality and Concurrency

[TODO: Mover-Thread entkoppelt Roboterbefehle vom Kameraloop; set_target statt blockierendem goto_target; Minimum-Jerk-Interpolation^[cite: Flash & Hogan], exponentielle Glatteung des Blickziels; verzögert nachdrehender Body als Traegheitseindruck. Begründung: biologisch plausible Bewegung als Bedingung fuer Anthropomorphismus und gegen das Uncanny Valley.]

G. Software Environment

The system runs under Python 3.12. Besides MediaPipe and Vosk, it uses OpenCV [2] for camera capture and visualisation, NumPy [3] for pose arithmetic, and the Reachy Mini SDK, which communicates with a daemon process that drives either the physical robot or a MuJoCo [11] simulation. [TODO: Versionen ergaenzen und pruefen, ob die Simulation im Paper ueberhaupt erwaeht werden soll.]

H. Evaluation Design

Das ist der wichtigste Unterabschnitt – ohne ihn sind die Ergebnisse in Abschnitt IV nicht nachvollziehbar.

[TODO: Reproduzierbarer Stimulus: eine einmal aufgezeichnete Videosequenz (Person naehert sich, laechelt, winkt, verlaesst das Bild) wird in alle Konfigurationen eingespeist, damit Unterschiede dem System und nicht dem Input zuzuschreiben sind.] The compared configurations are listed in Tab. 2.

[TODO: Messpunkte pro Frame mit `time.perf_counter()`: t_0 Frame gelesen, t_1 Inferenz fertig, t_2 Ziel/Emotion bestimmt, t_3 Befehl abgesetzt. Metriken: Reaktionszeit $t_3 - t_0$ als Median, IQR und p95; Inferenzanteil $t_1 - t_0$; effektive Bildrate; verworfene Frames. Wiederholbarkeit: zehn Durchlaeufer derselben Datei je Konfiguration.]

[TODO: Zwei getrennte Wiederholbarkeitsmasse definieren – auf Wahrnehmungsebene (erkannte Emotion je Frame) und auf Ausdrucksebene (gewaehlte Pose-Variante). Begruendung, warum das zweite absichtlich nicht konstant ist.]

Cfg	Perception	Concurrency	Extras
K1	Face detector	single thread	–
K2	Face detector	mover thread	body follow
K3	Face landmarker	mover thread	emotions, distance
K4	K3 + gestures	two skills	–

Tab. 2: The four evaluated skill configurations. K1→K2 isolates the effect of decoupling, K2→K3 the cost of the heavier model, and K3→K4 the behaviour under competing skills.

IV. EXPERIMENTAL RESULTS

Ziel: ca. 0,8–0,9 Seiten und damit der laengste Abschnitt. Regel: Was gebaut wurde, steht in III – hier steht nur, was das fertige System beobachtbar tut. Die Diskussion der Zahlen laeuft direkt mit.

A. Realised Behaviour

Verifies rows 1 and 6 of Tab. 1. [TODO: Beschreibender Durchlauf: Person betritt das Bild, naehert sich, laechelt, winkt, verschwindet – und was der Roboter jeweils tut. Kurz halten, zwei bis drei Saetze plus Verweis auf eine Bildsequenz im Anhang.]

B. Expressive Repertoire

Verifies row 2 of Tab. 1: how much affective range two antennas and a head actually carry. [TODO: Tabelle ausfuellen (siehe Anhang) und im Text auf die Beobachtung eingehen, welche Zustaende sich in den Antennenwinkeln naeherkommen und daher potenziell verwechselbar sind.]

[TODO: Falls im Hauptteil doch Platz bleibt: Tabelle aus dem Anhang hierher zurueckholen.]

C. Reaction Time

Verifies rows 3 and 5 of Tab. 1: contingency is a stated precondition for attribution and bonding, so latency is not a performance footnote here but the technical form of that requirement. [TODO: Boxplot der Reaktionszeit ueber K1–K4 einsetzen, dann zwei bis drei Saetze Interpretation: wo liegt der Median, wo bricht welche Konfiguration ein, welcher Anteil entfaellt auf die Inferenz.] Fig. 1 shows the distribution across configurations.



Fig. 1: Placeholder. Reaction time per configuration, shown as a box plot over all frames of the recorded stimulus sequence.

D. Repeatability

Verifies row 4 of Tab. 1. [TODO: Tabelle mit Streuungsmassen ueber die zehn Durchlaeufer. Interpretation: Wahrnehmung nahezu konstant, Ausdruck bewusst variabel.]

[TODO: Abschliessender Diskussionsabsatz – der inhaltlich wichtigste des Papers: Die gemessene Reaktionszeit ist die technische Entsprechung der in Abschnitt II-D beschriebenen Kontingenzbedingung. Zugleich besteht ein Zielkonflikt: Wiederholbarkeit ist auf Wahrnehmungsebene erwuenscht, auf Ausdrucksebene unerwuenscht, weil deterministische Wiederholung mechanisch wirkt. Vorsichtig formulieren – ohne Nutzerstudie keine Wirkungsangabe.]

V. SUMMARY AND OUTLOOK

Ziel: ca. 0,25 Seiten, zwei Absaetze.

[TODO: Absatz 1 – Zusammenfassung entlang des roten Fadens: Aus den psychologischen Mechanismen (II) wurden Entwurfsentscheidungen abgeleitet (Tab. 1), diese umgesetzt (III) und ihre technischen Voraussetzungen gemessen (IV). Klar sagen, was damit gezeigt ist – dass der Roboter die Mechanismen gezielt bedient und die

Bedingungen da fuer erfuehlt – und was nicht: die Wirkung auf Menschen selbst.]

[TODO: Absatz 2 – Ausblick mit Begrue ndung: (i) Nutzerstudie zur tatsaechlichen Wirkung, z.B. mit RoSAS^[cite: RoSAS] oder Godspeed^[cite: Godspeed]; (ii) Arbi- trierungsschicht zwischen Tracking und Emotionswieder- gabe, da beide auf dieselben Akteuren zugreifen; (iii) Anbindung der bereits vorhandenen Spracherkennung.]

REFERENCES

- [1] Alpha Cephei, “Vosk speech recognition toolkit,” <https://alphacephei.com/vosk/>, 2024, accessed: 2026-09-17.
- [2] G. Bradski, “The OpenCV library,” *Dr. Dobbs’s Journal of Software Tools*, 2000.
- [3] C. R. Harris, K. J. Millman, S. J. van der Walt *et al.*, “Array program- ming with NumPy,” *Nature*, vol. 585, no. 7825, pp. 357–362, 2020.
- [4] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann, “MediaPipe: A framework for building perception pipelines,” *arXiv preprint arXiv:1906.08172*, 2019.
- [5] I. Lütkebohle, F. Hegel, S. Schulz, M. Hackel, B. Wrede, S. Wachsmuth, and G. Sagerer, “The Bielefeld anthropomorphic robot head ‘Flöbi’,” in *2010 IEEE Int. Conf. Robotics and Automation (ICRA)*, Anchorage, AK, USA, 2010.
- [6] V. Nitsch and M. Popp, “Emotions in robot psychology,” *Biological Cybernetics*, vol. 108, no. 5, 2014.
- [7] H. T. Reis and P. Shaver, “Intimacy as an interpersonal process,” in *Handbook of Personal Relationships*, S. W. Duck, Ed. Chichester, UK: John Wiley & Sons, 1988.
- [8] A. Rogel, E. Yadollahi, and G. Laban, “Emotional expression in low- degrees-of-freedom robots: Assessing perception with Reachy Mini,” *arXiv preprint arXiv:2605.12786*, 2026.
- [9] A. M. Rosenthal-von der Pütten, F. P. Schulte, S. C. Eimler, L. Hoff- mann, S. Sobieraj, S. Maderwald, N. C. Krämer, and M. Brand, “Neural correlates of empathy towards robots,” in *Proc. 8th ACM/IEEE Int. Conf. Human-Robot Interaction (HRI)*, 2013.
- [10] A. P. Saygin, T. Chaminade, H. Ishiguro, J. Driver, and C. Frith, “The thing that should not be: predictive coding and the uncanny valley in perceiving human and humanoid robot actions,” *Social Cognitive and Affective Neuroscience*, vol. 7, no. 4, 2012.
- [11] E. Todorov, T. Erez, and Y. Tassa, “MuJoCo: A physics engine for model-based control,” in *IEEE/RSJ International Conference on Intelli- gent Robots and Systems (IROS)*, 2012, pp. 5026–5033.
- [12] A. Yim, A. P. Cui, and B. Price, “Carefree cuteness: The effect of exposure to cuteness on risk-seeking,” *European Journal of Marketing*, vol. 59, 2025.

APPENDIX

Hier hinein, was im Hauptteil keinen Platz hat:

Emotion	Antennas [°]	Head	Dur. [s]
neutral	−30/30	.	1.0
joy	−90/90	.	0.6
fear	−180/180	.	1.0
curious	−120/110	.	1.2
sad	−10/10	.	1.5
...	.	.	.

Tab. 3: Implemented expressive states and their antenna angles.

[TODO: Bildsequenz des Interaktionsablaufs, Konfusionsmatrix der Blendshape-Erkennung, Rohwerte der Latenzmessung.]